Del CSV al modelo

Analizar, detectar señales y predecir con datos de ventas

Laboratorio de Inteligencia Artificial

¿Podemos estimar cuántas unidades se venderán usando visitas y descuento?

- Partimos de una tabla CSV, como en la primera práctica.
- Usamos limpieza y agrupación antes de modelar.
- Evaluamos una predicción con datos que el modelo no vio.

1. Cargar y revisar: tipos, faltantes, rangos.
2. Transformar: crear el importe y agrupar por ciudad.
3. Investigar: marcar posibles valores atípicos.
4. Aprender: ajustar una regresión a partir del CSV.
5. Evaluar: comparar el error con una predicción de referencia.

Conexión con clases anteriores

Es aprendizaje supervisado: el CSV contiene entradas y una respuesta conocida para aprender, como en la predicción de estaturas.

fecha	visitas	descuento_pct	unidades
2026-01-01	95	7	12
2026-01-02	372	25	39
2026-01-03	257	9	29

- 240 días sintéticos; hay una celda faltante y dos ventas inusuales.
- La columna `unidades` es el objetivo que queremos estimar.
- Las variables `visitas` y `descuento_pct` son las entradas.

```
with open("ventas_clase.csv", newline="") as archivo:
    lector = csv.DictReader(archivo)
    filas = list(lector)

print(lector.fieldnames)
print(filas[:2])
```

Por qué importa

CSV guarda texto. Las conversiones a número deben ser explícitas, y una celda vacía requiere una decisión antes de calcular.

```
limpios = []
for fila in filas:
    try:
        unidades = float(fila["unidades"])
        precio = float(fila["precio_unitario"])
    except ValueError:
        continue
    fila["importe"] = unidades * precio
    limpios.append(fila)
```

- La práctica descarta filas incompletas solo en los campos necesarios.
- El resumen por ciudad describe el CSV; no explica por qué difieren las ciudades.

Para una variable numérica, el rango intercuartílico es $IQR = Q_3 - Q_1$.

$$\text{marcar si } x < Q_1 - 1.5\,IQR \quad \text{o} \quad x > Q_3 + 1.5\,IQR$$

- La regla detecta valores alejados del centro de la distribución.
- Una promoción exitosa puede ser un valor extremo real.
- Igual que con Benford: anomalía no significa fraude; hay que revisar contexto y origen.

Primeros días: entrenamiento	Últimos días: prueba
aprende los coeficientes	mide errores en días no usados

- En datos temporales, no mezclamos el futuro con el pasado.
- Un buen resultado de entrenamiento no basta: interesa la prueba.
- No usamos columnas que revelen directamente la respuesta: eso sería fuga de información.

Suponemos una relación lineal:

$$\widehat{\textit{unidades}} = b_0 + b_1\,\textit{visitas} + b_2\,\textit{descuento}$$

- `numpy.linalg.lstsq` busca coeficientes que ajusten el entrenamiento.
- No es una red neuronal, pero practica el mismo ciclo: ejemplos, ajuste y evaluación.
- Los coeficientes describen asociaciones en estos datos sintéticos, no causalidad.

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

- Si el MAE es 4, la predicción se equivoca en promedio por 4 unidades.
- Comparamos con una referencia simple: predecir siempre la media del entrenamiento.
- El modelo solo es útil si supera una referencia razonable en datos de prueba.

```
x_train = np.column_stack([np.ones(len(train)), train_x])
x_test = np.column_stack([np.ones(len(test)), test_x])
b = np.linalg.lstsq(x_train, y_train, rcond=None)[0]
prediccion = x_test @ b
mae = np.mean(np.abs(y_test - prediccion))
```

Antes de ejecutar

¿Qué variable creen que pesará más? ¿Qué cambiaría si quitamos el descuento de las entradas?

- Revisar cuántas filas se conservaron y cuántos posibles atípicos aparecieron.
- Comparar MAE de referencia y MAE del modelo.
- Si falla, investigar: ¿datos ruidosos, relación no lineal, cambios con el tiempo?

Límite del ejemplo

Los datos son sintéticos y sencillos. Una asociación predictiva no demuestra que aumentar visitas o descuentos cause más ventas.

- Un CSV de episodios del robot puede tener sensores, acción, choque y recompensa.
- El mismo flujo permite predecir una recompensa o detectar episodios extraños.
- Embeddings y RAG son otra ruta: buscar semánticamente en texto asociado a los registros, no sustituir esta auditoría tabular.

Idea común

Los modelos dependen de la calidad de los datos, de una pregunta clara y de una evaluación honesta.

1. Ejecutar `python3 generar_ventas.py`.
2. Ejecutar `python3 analizar_ventas.py`.
3. Cambiar las entradas a solo `visitas`; comparar los MAE.
4. Probar otra proporción temporal, por ejemplo 70/30.
5. Inspeccionar las fechas marcadas como atípicas antes de decidir eliminarlas.

Entrega: cambio, predicción previa, resultado observado y una limitación del análisis.

$$\text{CSV} \rightarrow \text{preguntas} \rightarrow \text{modelo} \rightarrow \text{evaluación}$$

Un modelo no arregla datos confusos ni convierte una correlación en causa.