

Del CSV al análisis de datos

Cargar, inspeccionar y manipular una tabla con Python

Inteligencia Artificial

Al terminar, podremos:

- explicar qué contiene un archivo CSV y cómo se organiza;
- cargarlo con pandas y revisar sus filas, columnas y tipos;
- detectar valores faltantes, filtrar filas y crear una columna;
- resumir datos para responder una pregunta concreta.

Conexión con el laboratorio del robot

Guardar posición, acción, choques y distancia a la meta en un CSV permite comparar recorridos y generaciones con evidencia.

- Cada línea representa un registro (una fila).
- La primera línea suele nombrar las columnas.
- Un separador, normalmente coma, divide los campos.
- Conviene mantener una unidad y un significado coherentes por columna.

Ejemplo: ventas_sinteticas.csv

```
fecha,ciudad,categoria,producto,unidades,precio_unitario  
2026-03-02,Valparaiso,Bebidas,Cafe,3,2.50  
2026-03-03,Santiago,Alimentos,Pan,5,1.20
```

La coma separa columnas; el punto representa decimales en este conjunto.

Coloca el CSV y el script en la misma carpeta. En una terminal:

```
python -m pip install pandas  
python explorar_ventas_csv.py
```

- En algunos equipos Linux, el comando puede ser `python3`.
- `pandas` organiza datos tabulares en un objeto llamado `DataFrame`.
- El script usa una ruta relativa a su propia ubicación, no a la carpeta actual de la terminal.

```
from pathlib import Path
import pandas as pd

ruta = Path(__file__).with_name("ventas_sinteticas.csv")
datos = pd.read_csv(ruta, parse_dates=["fecha"])

print(datos.head())
print("Dimensiones:", datos.shape)
```

Qué comprobamos

`head()` muestra las primeras filas; `shape` devuelve (filas, columnas). Parsear la fecha permite tratarla como fecha y no como texto.

```
print(datos.columns.tolist())  
print(datos.dtypes)  
print(datos.isna().sum())  
print(datos.select_dtypes(include="number").describe())
```

- `columns`: nombres disponibles.
- `dtypes`: tipo inferido para cada columna.
- `isna().sum()`: cantidad de celdas faltantes.
- `select_dtypes()` y `describe()`: seleccionan y resumen columnas numéricas.

No asumir

Un número leído como texto, una fecha mal interpretada o un valor faltante pueden cambiar el análisis.

```
limpios = datos.dropna(subset=["unidades", "precio_unitario"]).copy()
limpios["importe"] = limpios["unidades"] * limpios["precio_unitario"]

print("Filas originales:", len(datos))
print("Filas utilizables:", len(limpios))
print(limpios[["producto", "unidades", "importe"]].head())
```

Decisión de análisis

Aquí excluimos registros sin unidades o precio para calcular el importe. En otro problema podríamos corregirlos o conservarlos: primero hay que entender por qué faltan.

```
ventas_grandes = limpios[limpios["importe"] >= 10]
print(ventas_grandes.sort_values("importe", ascending=False))

por_categoria = limpios.groupby("categoria").agg(
    ventas_totales=("importe", "sum"),
    unidades_totales=("unidades", "sum"),
    numero_registros=("producto", "count"),
)
print(por_categoria.sort_values("ventas_totales", ascending=False))
```

- Filtrar: quedarse con filas que cumplen una condición.
- Ordenar: comparar registros de mayor a menor.
- Agrupar: resumir por una categoría con suma, promedio o conteo.

- ❶ ¿Qué categoría suma más ventas? ¿Y cuál reúne más unidades?
- ❷ ¿Cuántas filas se descartaron y por qué?
- ❸ ¿Una venta total alta significa que se vendieron muchas unidades?
- ❹ ¿Qué información adicional necesitaríamos para explicar el resultado?

Un resumen no es una explicación causal

Una agrupación describe los datos disponibles. Por sí sola no explica por qué ocurrió el patrón ni garantiza que represente otros periodos.

Kaggle Datasets

<https://www.kaggle.com/datasets>

Busca conjuntos que indiquen formato CSV y tengan una descripción y un diccionario de columnas. Algunos requieren iniciar sesión para descargarlos.

- Revisa la licencia y las condiciones de uso antes de reutilizar los datos.
- Comprueba separador, codificación, unidades, fechas y valores faltantes.
- Evita publicar datos personales o sensibles.

Alternativa: <https://datasetsearch.research.google.com/> para encontrar conjuntos publicados en distintos repositorios.

- 1 Ejecuta `explorar_ventas_csv.py` y explica cada salida.
- 2 Cambia el filtro: ¿qué filas tienen más de 4 unidades?
- 3 Agrupa por ciudad y compara el importe total.
- 4 Propón columnas CSV para registrar una trayectoria del robot.

Posible registro del robot

`generacion, episodio, paso, fila, columna, accion, choque, distancia_meta, fitness`

Cargar es solo el comienzo.

Inspeccionar, limpiar, transformar y preguntar convierten una tabla en evidencia útil.