Autopsia de una Red Neuronal

¿Qué Aprende Realmente la IA Cuando Nadie la Vigila?

Laboratorio de Inteligencia Artificial — Sesión Magistral de Interpretabilidad

14 de octubre de 2026

Deep Learning, Diagnóstico Forense y Límites de la IA

Prólogo: Hoy Nadie Deriva Nada

Lo que ya conquistamos

En las sesiones previas construimos el pipeline completo:

- Backpropagation y optimización con Adam.
- Curvas de aprendizaje y diagnóstico de sobreajuste.
- Parada temprana (*Early Stopping*) y checkpoints en disco (`mejor_modelo.pth`).

El Cambio de Rol Hoy

Hoy colgamos el traje de programadores matemáticos y nos ponemos la bata de **detectives forenses**.

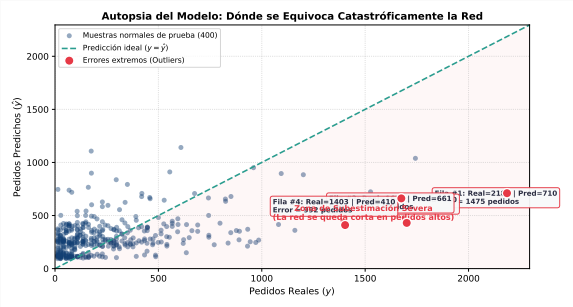
La Pregunta Incómoda

≪El modelo entrenó sin errores y la pérdida bajó... pero ¿realmente aprendió economía de demanda, o solo encontró una trampa para engañarnos?≫

La Agenda de Hoy:

1. **Acto 1**: Los peores fallos reales de nuestra red.
2. **Acto 2**: El efecto Clever Hans (lobos, nieve y rayos X).
3. **Acto 3**: La trampa de la extrapolación.
4. **Acto 4**: El mapa del zoológico de la IA.

Acto 1: La Autopsia Forense de Nuestro Modelo



Los Datos No Mienten (`predicciones_prueba.csv`):

Real (y)	Predicho ($\hat{y}$)	Error Absoluto
1,701	431	**1,270 pedidos**
944	253	**691 pedidos**
770	225	**545 pedidos**
161	**766**	**605 pedidos**

El Patrón Detectado:

- Cuando la demanda explota (> 900), la red **colapsa hacia abajo**.
- Predice tímidamente entre 200 y 450 pedidos.
- ¿Por qué una red con 241 pesos comete este error sistemático?

¿Por qué Falló la Red? La Trampa de la Pérdida Cuadrática

La Matemática Detrás de la Cobardía

Nuestra función de pérdida fue el Error Cuadrático Medio:

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$$

- En el dataset, el 95 % de las semanas tienen entre 50 y 350 pedidos (promedio real: 258).
- Si la red se arriesga a predecir $1,500$ pedidos y esa semana solo hubo 200, el error cuadrático es:

$$(1,500 - 200)^2 = 1,690,000 \quad \text{(Pena capital)}$$

- La red descubrió que **apostar al promedio** es la estrategia más segura para mantener el gradiente bajo control.

La Primera Gran Lección

La red no es tonta, es obediente:

- Optimizó a la perfección la función matemática que nosotros le dimos.
- Si le pides minimizar $(y - \hat{y})^2$, sacrificará la precisión en los días extraordinarios para protegerse en los días ordinarios.
- **Solución de ingeniería**: Transformación logarítmica $\log(1 + y)$ o función Huber Loss en problemas asimétricos.

Acto 2: El Fenómeno “Clever Hans” en Machine Learning

Alemania, 1904: El Caballo Sabio

Clever Hans era un caballo que supuestamente sabía sumar, restar y multiplicar:

- Su dueño le preguntaba: $\ll$*¿Cuánto es* $3+2$*?*$\gg$
- El caballo golpeaba el suelo con el casco 5 veces y se detenía.
- Científicos de toda Europa viajaron a certificar el “milagro”.

El Experimento del Dr. Oskar Pfungst

Pfungst aisló al caballo del público y del dueño:

- El caballo **falló por completo**.
- Descubrimiento: Hans no sabía aritmética; leía la tensión en las cejas y respiración del público cuando llegaba al número correcto.

El Paralelismo con Deep Learning

- Las redes neuronales son los **Clever Hans modernos**.
- No comprenden conceptos semánticos ni causas físicas.
- Son máquinas estadísticas implacables que explotarán **cualquier atajo accidental (shortcut)** en los datos con tal de bajar la pérdida.

Caso de Estudio 1: El Lobo y la Nieve (Fotos Reales)

Caso Real: "Why Should I Trust You?" (Ribeiro et al., KDD 2016)

(a) Foto Original de Entrada (Un Husky en la nieve)



Predicción del Modelo: "LOBO" (Error en Test)

(b) Explicación con LIME (Píxeles que activaron la neurona)



Atajo Detectado: ¡La red solo miró la nieve!

El Paper Seminal de LIME (2016)

Ribeiro et al. entrenaron una red profunda para **Lobos vs. Huskies**:

- Precisión casi perfecta en test ($> 95\,\%$).
- Ante este husky real, predijo **"LOBO"** con total seguridad.

La Autopsia de Píxeles

AI aplicar LIME para ver qué activó la neurona:

- El perro fue **ignorado por completo**.
- La decisión se basó exclusivamente en la **nieve blanca del fondo**.
- *Conclusión*: La red jamás aprendió animales; aprendió un detector de nieve.

Caso de Estudio 2: Radiografías de COVID y la Letra de Metal

El Desafío Clínico de 2020

Durante el pico de la pandemia se publicaron cientos de modelos de Deep Learning que prometían detectar COVID-19 en radiografías de tórax con 95 %+ de sensibilidad:

- Se entrenaron con radiografías de decenas de hospitales del mundo.
- Parecía un triunfo absoluto de la inteligencia artificial médica.

La Autopsia Científica (Nature, 2021)

Científicos de Cambridge auditaron más de 400 modelos y descubrieron que **ninguno servía en clínica**:

- Los pacientes graves en UCI se escaneaban con equipos portátiles que dejaban una pequeña letra "R" metálica o tipografías distintas.

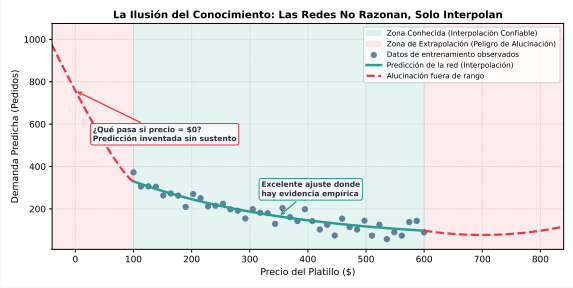
El Atajo Mortal

La red neuronal aprendió a clasificar:

¿Qué máquina de rayos X tomó la foto?
en vez de
¿El pulmón tiene neumonía?

Al llevar el modelo a un hospital nuevo sin esas marcas, la precisión cayó al azar (50 %).

Acto 3: ¿Por qué la Red no Razona? Interpolar vs. Extrapolar



La Metáfora de la Sábana de Goma

Una red neuronal es como una sábana elástica en alta dimensión:

- **Interpolación (Dentro del dominio)**: La sábana se dobla con gracia para tocar todos los puntos observados. Aquí la red es excelente.
- **Extrapolación (Fuera del dominio)**: Fuera de los postes donde clavamos los datos, la sábana ondea en cualquier dirección impredecible.

La Regla de Oro

Las redes neuronales **nunca te dirán ≪no sé≫**. Ante una entrada delirante, te responderán un número absurdo con 100 % de seguridad numérica.

Experimento de Estrés (Stress Testing) con Nuestro Modelo

¿Qué responde `mejor_modelo.pth` si le hacemos preguntas fuera de su universo?

Pregunta al Modelo	Lógica Económica Real	Comportamiento de la Red
Precio = **$0.00** (Comida gratis)	Demanda infinita / colapso de inventario	Predice un valor finito arbitrario ($\sim$ 500 pedidos) porque jamás vio un precio menor a $130.
Precio = **$100,000.00** (Precio astronómico)	Demanda exactamente 0	Predice números positivos absurdos debido a la saturación de las capas lineales.
Semana = **999** (20 años en el futuro)	Incertidumbre total	Extrapola linealmente el peso asignado a `week`, disparando la predicción sin control.

Conclusión de la Prueba de Estrés

El modelo carece de sentido común. No sabe qué es el dinero, qué es el apetito ni qué es una semana. Solo calcula $\sigma(Wx + b)$.

Ingeniería de Mitigación: Enjaular a la Bestia en Producción

En la industria seria, una red neuronal **jamás se conecta directamente al cliente sin blindaje**:

1. Vallas de Entrada (Guardrails)

Validar el dominio antes de tocar la red:

- `assert 100 <= precio <= 800`
- Si el dato está fuera, rechazar o recortar al percentil permitido (*clipping*).

2. Reglas Fijas de Negocio

Combinar IA con lógica determinista:

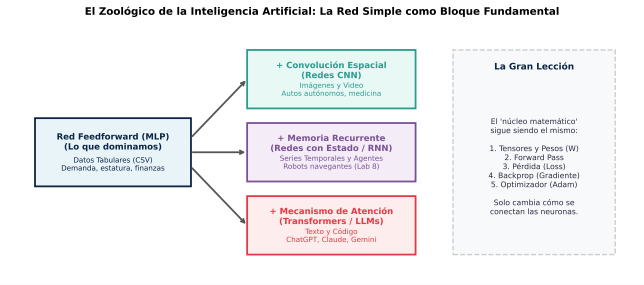
- ≪Si precio es cero, no consultes a la red; activa protocolo de promoción gratuita≫.
- La IA asesora; el código duro manda.

3. Detección OOD (Out-of-Distribution)

Calcular la distancia de Mahalanobis:

- ¿Este cliente se parece a los datos históricos?
- Si la distancia es alta $\Longrightarrow$ encender alarma de baja confianza.

Acto 4: El Zoológico de la IA (Hacia Dónde Vamos)



Lo que Ya Dominas:

- Red densa feedforward (MLP) para tablas y números continuos.
- Entendiste el ciclo completo: Datos → Tensores → Pérdida → Gradiente → Checkpoint.

La Conexión con los Próximos Temas:

- Para imágenes: añadiremos **convoluciones** (CNNs).
- Para secuencias y navegación de robots: añadiremos **memoria temporal** (como en el Lab 8 del robot).

Las Cuatro Reglas de Oro del Ingeniero de IA

1. La Métrica Única es una Ilusión

Tener un R^2 decente o un 98 % de precisión no significa nada si no abres la gráfica de residuos y miras los casos individuales donde el modelo falló.

2. La Red Siempre Hará Trampa

Si hay una correlación espuria (nieve, marcas de agua, orden temporal), el optimizador la aprenderá antes que el concepto real.

3. Conoce las Fronteras de tu Sábana

El modelo solo es dueño del espacio donde tiene datos. Fuera de ahí, no es inteligencia artificial: es generación aleatoria de números con arrogancia matemática.

4. Tu Valor no es Tunear el Learning Rate

Cualquiera puede correr `optimizer.step()`. El verdadero ingeniero es quien sabe cuándo el modelo está mintiendo y cómo proteger el sistema real.

¿Preguntas o Comentarios?

Pueden dejar sus reflexiones en el chat:
¿Cuál caso de fallo de IA les pareció más peligroso o curioso?